OncoGO-CRC

Guía pública de la versión 2
Qué se estudió, qué se encontró y qué no significa para un paciente

Este documento resume un trabajo de investigación sobre proteínas del cáncer de colon. Está escrito para alguien sin formación en biología molecular ni en estadística. Los números salen de tablas del proyecto; no son opiniones ni recomendaciones médicas.

Ningún resultado de este trabajo sirve para decidir sobre un paciente. No sustituye a un médico, a una prueba de laboratorio ni a un tratamiento.

1. ¿De qué va este proyecto?

El cáncer de colon es un tumor del intestino grueso. Las células del tumor producen proteínas —moléculas que hacen el trabajo dentro y fuera de la célula— de forma distinta al tejido sano de al lado. Si esa diferencia se repitiera en varios estudios independientes, podría ayudar a entender la enfermedad y, con muchísimo más trabajo después, a pensar en marcadores en sangre. Ese «después» no está aquí.

OncoGO-CRC es un programa de ordenador que descarga datos públicos de varios laboratorios, los compara con reglas fijas escritas antes de mirar los resultados, y deja un informe reproducible. No se tocan los datos originales. No se inventan valores donde falta una medición.

2. ¿Qué datos se usaron?

- Tejido de colon de 94 personas con tumor y tejido normal de la misma persona (estudio CPTAC, tecnología TMT).
- Tejido de 16 personas con tumor, normal y pólipo del mismo paciente (estudio PRIDE PXD034575).
- Tejido de 22 pares tumor–normal de otra cohorte (PRIDE PXD019504), para comprobar si los resultados se parecen entre estudios.
- Sangre: 20 muestras de personas con cáncer y 20 de personas sanas (PRIDE PXD055218).
- Datos clínicos de cientos de tumores de TCGA: nivel de CEA en sangre, pureza tumoral medida por ADN, expresión del gen CEACAM5.
- Literatura clínica sobre sensibilidad y especificidad del CEA frente a otras pruebas (meta-análisis de tablas 2×2).

Cada fuente tiene su propia tecnología. Por eso no se mezclan en un solo modelo: primero se analiza por dentro, y después se comparan los resultados.

3. La pregunta principal

La hipótesis H1 preguntaba si las proteínas que cambian en el primer estudio grande coincidirían poco con las del segundo. Si la coincidencia fuera baja (menos del 70 % en dirección), la hipótesis se consideraría apoyada. Si fuera alta, se rechazaría.

En CPTAC, con 94 pares, 688 proteínas pasaron el umbral de cambio mínimo (más del 50 % arriba o abajo, con corrección por comparar miles de proteínas a la vez). En la réplica pareada de 16 pares, 160 proteínas pasaron el mismo filtro.

De las proteínas que se pueden comparar entre cohortes, el 87,4 % mantiene la misma dirección (sube o baja). Eso está por encima del 70 %, así que H1 se rechaza por la cláusula de proteína: la dirección es más reproducible de lo que el diseño esperaba.

4. Los cinco indicadores resumen (R1 a R5)

El certificado no resume todo en una sola nota. Usa cinco piezas separadas:

- R1 — Dirección. 87,4 % de las proteínas comparables van en la misma dirección en dos cohortes distintas.
- R2 — Detectabilidad. Solo el 32,8 % de lo encontrado en el estudio grande aparece medible en la cohorte pequeña con la misma regla.
- R3 — Heterogeneidad entre estudios. El meta-análisis con tres cohortes de tejido da un I^2 del 9,4 %: los estudios discrepan más de lo que coinciden en magnitud.

- R4 — Composición del tejido. Tras ajustar por cuánto estroma hay en cada muestra, queda el 44,8 % de los hallazgos originales. Es una cota: parte de lo que parece «del tumor» es mezcla de tejidos.
- R5 — Azar. Al permutar las etiquetas tumor/normal cien veces, ninguna repetición igualó lo observado. El contraste no es un truco de etiquetas.

5. Lo más importante para entender los resultados

5.1 Mucho de la señal es composición, no tumor puro

El «normal» de estos estudios es tejido de al lado del tumor, no sangre de una persona sana. Trae músculo, matriz y células que no son el epitelio canceroso. Cuando se corrige por esa mezcla, más de la mitad de las proteínas dejan de pasar el umbral. Leer una lista de proteínas sin ese contexto es leer estroma y músculo como si fueran el tumor.

5.2 El tejido no predice la sangre

Una proteína que sube en el tumor no sube automáticamente en suero. CEACAM5 —la proteína del antígeno CEA— sube en tejido, pero el barrido proteómico de plasma usado aquí no la detecta. La sangre y el tumor miden cosas distintas con tecnologías distintas.

5.3 El CEA en sangre depende poco de cuánto gen expresa el tumor

En TCGA, 594 tumores tienen datos clínicos y de expresión. Añadir CEACAM5 al modelo clínico completo solo aporta el 2,3 % extra de variación del CEA. El marcador en sangre depende sobre todo de cuánto tumor hay y de dónde está, no de cuánto gen expresa el tumor.

5.4 Separar cáncer de sano no es lo mismo que separar cáncer de enfermo

Con la misma plataforma, distinguir cáncer de personas sanas da un AUC de 0,994, pero distinguir cáncer de pacientes con síntomas que no tenían cáncer baja a 0,800. En consulta llegan personas enfermas de otra cosa, no voluntarios sanos.

6. Qué aportó la versión 2 respecto a la primera corrida

- Permutaciones con semilla fija para comprobar que el resultado no es azar.
- Denominadores explícitos en cada fracción (cuántas proteínas entran y por qué).
- Ajuste por composición sin usar la misma proteína para medir y para corregir.
- Pólipos analizados por separado, no mezclados con tumor–normal.
- Cláusula de vías: un término solo cuenta si tiene al menos diez proteínas.
- Tercera cohorte de tejido para estimar heterogeneidad entre estudios.
- Verificador automático: si un número del informe no sale de una tabla, el informe no se publica.
- Nueve fuentes externas (TCGA, pureza ABSOLUTE, heterogeneidad intratumoral, deconvolución celular, plasma frente a enfermedad benigna, meta-análisis de marcadores, protocolo de cohorte futura).

7. Nuevas comprobaciones en lenguaje llano

Pureza medida con otra tecnología

El índice de estroma que usa el proyecto va en el sentido correcto frente a la pureza medida por ADN (correlación −0,228), pero solo comparte el 5,2 % de la variación. No sustituye a la pureza del patólogo.

Variación dentro del mismo tumor

Medir un solo trozo de tumor es medir un trozo, no el tumor entero. Con cuatro pacientes y remuestreo, la variación dentro del tumor y entre pacientes es del mismo orden (cociente 1,273, intervalo incluye el 1). Es una señal, no una conclusión cerrada.

Deconvolución celular

Intentar estimar proporciones de tipos celulares no funciona en la matriz TMT de CPTAC: el 52,5 % de los valores es negativo, y una mezcla lineal no negativa no puede reproducirlos. Las proporciones tipo a tipo no se publican; solo se usa un eje epitelial como comprobación de sensibilidad cuando los datos lo permiten.

Rendimiento publicado del CEA

Según 8 estudios extraídos de la literatura (pendientes de verificación humana fila a fila), el CEA para detectar recaída tiene sensibilidad 60,5 % y especificidad 87,9 %: de cada diez recaídas, deja pasar cerca de cuatro. Ese es el listón que cualquier alternativa debería superar con evidencia comparable.

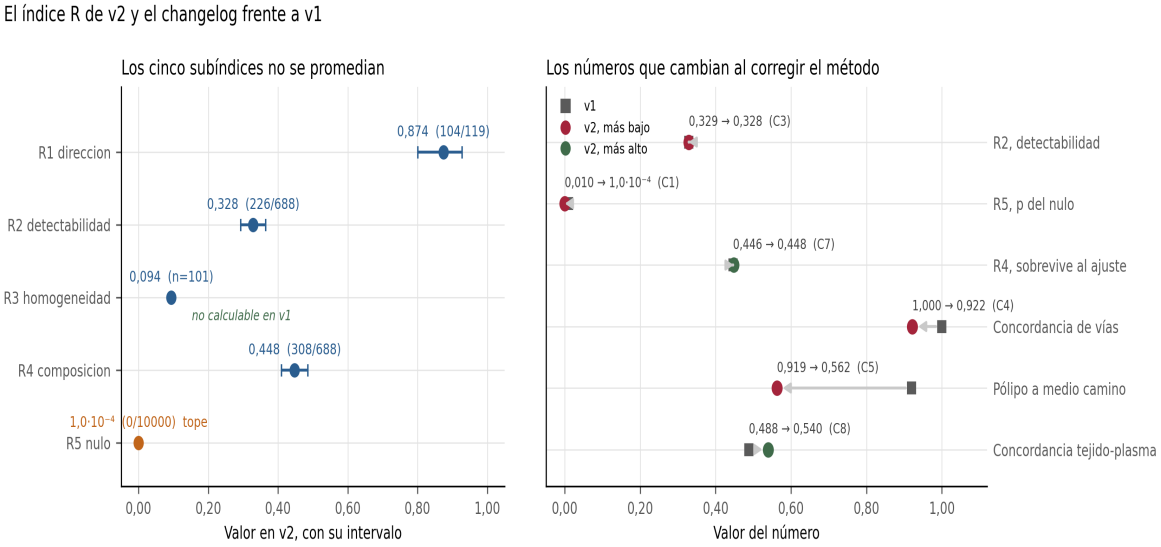
8. Qué hay en el repositorio

El código fuente está en GitHub (rama principal tras integrar v2). Los datos pesados viven en un disco de datos local; el repositorio incluye los informes en PDF, las tablas de resumen y la documentación para reproducir el análisis.

- docs/reportes/OncoGO-CRC_guia_publica_v2.pdf — este documento.
- docs/reportes/OncoGO-CRC_informe_v2.pdf — informe técnico completo con figuras.
- docs/reportes/OncoGO-CRC_informe_v2_tecnico.pdf — copia del informe de la corrida.
- results/v2/report/ — HTML, Markdown y figuras generadas desde tablas.
- config/preregistro_v2.yaml — reglas fijadas antes de mirar los datos.
- docs/fuentes_datos.md — origen, licencia y limitaciones de cada fuente.

- docs/enmiendas_v2.md — cambios declarados respecto al preregistro.

9. Figura: índice R y cambios respecto a v1



Cada barra es un subíndice. No se promedian en una sola nota porque miden cosas distintas: dirección, detectabilidad, heterogeneidad, composición y azar.

10. Conclusión honesta

Con datos públicos y reglas fijas, se puede afirmar que hay muchas proteínas que cambian entre tumor y tejido adyacente, que la dirección se repite más de lo esperado entre cohortes, que buena parte de la señal es composición de tejidos, que el tejido no predice la sangre, y que el CEA depende poco de la expresión génica del tumor.

No se certifica ningún biomarcador, ninguna diana terapéutica ni ninguna recomendación clínica. Este trabajo es investigación reproducible, no una prueba médica.