Qué parte del tumor colorrectal se deja ver en la sangre

Juan Diego Polanco Franco

Universidad de Caldas

Facultad de Inteligencia Artificial e Ingenierías

Manizales, Colombia

2026

Qué parte del tumor colorrectal se deja ver en la sangre

Juan Diego Polanco Franco

Tesis o trabajo de investigación presentada(o) como requisito parcial para optar al título de:

Magíster en Bioinformática y Biología Computacional

Programa de investigación, 60 créditos, SNIES 103917.
Convenio SUMA con la Universidad de Manizales, la Universidad Autónoma de Manizales y la Universidad Católica de Manizales.

Director:

Doctor en Ingeniería, Jorge Alberto Jaramillo Garzón

Grupo de investigación:

Grupo de Investigación en Tecnologías de la Información y Redes (GITIR)

Línea de investigación:

Modelos Computacionales y Bioinformática

Universidad de Caldas

Facultad de Inteligencia Artificial e Ingenierías

Manizales, Colombia

2026

Andamiaje, 11 de noviembre de 2026. No es la prosa final.

Declaración de uso de herramientas de inteligencia artificial

Objetivo de la sección. Declarar qué herramienta se usó, con qué versión o fecha, para qué y hasta dónde. Ninguna de estas herramientas es fuente de un hecho científico.

% TODO Juan Diego: Reescribe la tabla con tus palabras si quieres cambiar el propósito o el alcance. La versión y la fecha ya están.

Cuadro 1: Herramientas de inteligencia artificial usadas en el trabajo

Herramienta	Versión o fecha	Propósito	Alcance
Cursor (Anysphere)	3.28.7	Escribir y depurar código	El autor revisó, ejecutó y validó el código
SciSpace	Consultado entre 2026-03 y 2026-11	Buscar y hacer un primer filtro de literatura	No sustituye la lectura del artículo

Fuente: Declaración del autor. No es un resultado de `results/v3_7/`.

% TODO Juan Diego: Ajusta este párrafo.

Se utilizó Cursor (Anysphere) como asistente de programación para escribir y depurar código, y SciSpace como apoyo para buscar y hacer un primer filtro de literatura científica. El código, los resultados y las fuentes fueron revisados, ejecutados y validados por el autor, quien asume la responsabilidad total del contenido. Anysphere, 2026; SciSpace, 2026

Resumen

Objetivo de la sección. Un resumen analítico de máximo 250 palabras, con objetivo, diseño, métodos, resultados y conclusión, y de 3 a 7 palabras clave.

% TODO Juan Diego: Redacta el resumen. No copies estas viñetas. Máximo 250 palabras.

Datos que sí están en `results/v3_7/`:

- Pregunta: qué parte del cambio del tumor se deja ver en la sangre cuando el contraste es otra enfermedad intestinal. Rai et al., 2025; Tanaka et al., 2024; Vasaikar et al., 2019
- Celda del suero, CP frente a CN: 284 proteínas; 0 diferentes; 166 equivalentes; 118 indeterminadas.
- Concordancia de signo del tumor primario, Tanaka y CPTAC: 147 de 147.
- Modelos: todas las proteínas, AUC 0,880; solo calidad, 0,915; sin la calidad, 0,647 (p de permutación 0,12).
- H5, Sostiene. H6, No sostiene. H7, Refuta. H8, No evaluable. H9, Exploratorio. H10, Descriptiva.
- El certificado está en Publicable. No es un examen de sangre. Pepe et al., 2001

Preguntas guía:

- ¿Qué se preguntó y qué contraste decide esa pregunta?
- ¿Qué salió en la celda y qué no demuestra el cero de la clase diferente?

- ¿Por qué la separación del modelo no se presenta como una proteína del tumor?

Extensión orientativa: 200 a 250 palabras. Citas sugeridas: Lakens, 2017; Pepe et al., 2001; Rai et al., 2025; Tanaka et al., 2024; Vasaikar et al., 2019.

Palabras clave: cáncer colorrectal; proteómica; suero; especificidad; calidad de muestra.

% TODO Juan Diego: Deja entre 3 y 7 palabras clave. Revisa si «calidad de muestra» es la quinta que quieres conservar.

Abstract

Objetivo de la sección. Traducir el resumen al inglés, con las mismas cifras y sin añadir un resultado.

% TODO Juan Diego: Write the abstract from your Spanish summary. Do not translate these bullets as the final paragraph. At most 250 words.

Facts already in `results/v3_7/`: serum cell 0 different, 166 equivalent and 118 indeterminate out of 284; tissue sign concordance 147 of 147; AUC 0,880, 0,915 and 0,647 (permutation p 0,12); H7 is Refuta; the certificate is Publicable. This is not a blood test.

Keywords: colorectal cancer; proteomics; serum; specificity; sample quality.

Tabla de contenido

Declaración de uso de herramientas de inteligencia artificial **V**

Resumen **VII**

Abstract **IX**

Lista de abreviaturas **XIX**

1. Introducción **1**

1.1. Campo y problema 1

1.2. Justificación 2

1.3. Pregunta 2

1.4. Objetivos 2

1.5. Alcance 3

2. Marco teórico y estado del arte **5**

2.1. Matrices que no se fusionan 5

2.2. Cómo se declara un cambio 6

2.3. Ontología y modelos 6

2.4. Estado del arte que cambia la lectura 6

3. Materiales y métodos **9**

3.1. Cohortes 9

3.2. Reglas de inferencia 10

3.3. Modelos y priorización 10

3.4. Lo que el método no hizo 11

3.5. Entorno 11

3.6. Uso de herramientas de inteligencia artificial 11

4. Resultados **13**

4.1. Mapa de la corrida 13

4.2. Tejido 14

4.3. Suero 15

4.4. Calidad, orden y modelos 16

4.5. Hipótesis y priorización 17

5. Discusión **21**

5.1. Qué se puede leer 21

5.2. Limitaciones 22

5.3. Desviaciones del preregistro 22

6. Conclusiones y recomendaciones **23**

6.1. Conclusiones 23

6.2. Recomendaciones y trabajo futuro 24

7. Anexos **25**

7.1. Correspondencia con la propuesta 25

7.2. Entorno y código 26

7.3. Ficheros que la especificación nombra y no están 27

Referencias bibliográficas **29**

Índice de cuadros

1. Herramientas de inteligencia artificial usadas en el trabajo V

3.1. Matrices leídas por la corrida v3.7 9

4.1. Celda preregistrada del suero, CP frente a CN 15

4.2. Estado de las hipótesis en la corrida firmada 17

Índice de figuras

4.1. Cuatro bloques de la corrida: tejido, suero, hipótesis y priorización. El trazo une el orden de lectura. No representa una proteína que pasa del tumor a la sangre. 13

4.2. Cada punto es un gen de la tabla de H7 medido también en Tanaka. El eje horizontal es el $\log_2$FC de CPTAC y el vertical, el de Tanaka. 14

4.3. Cada punto es un término con FDR de CPTAC dentro del umbral y con NES en Tanaka. 15

4.4. Embudo del suero. Alturas: 897 grupos, 329 con el filtro global, 312 humanas y la celda de 284. 16

4.5. La barra superior es CP frente a CN. Las de abajo son los contrastes con HC, medido aparte: 3 diferentes en CP y 1 en CN. HC no decide la pregunta. . . 17

4.6. AUC fuera de pliegue de M1 a M6. La línea discontinua es el percentil 95 del nulo de K5. 18

4.7. Media del valor absoluto de SHAP en M2 y en M3. M3 usa las variables de calidad que trae el fichero. 19

4.8. Rejilla de 288 celdas. El trazo discontinuo marca las que tienen alguna proteína diferente. No es una cohorte nueva. 19

4.9. Controles de tejido no medibles. AQP8, GUCA2A y SLC26A3 quedan con trazo discontinuo porque el fichero no los da para la prueba. 20

Lista de abreviaturas

% TODO Juan Diego: Revisa cada fila y borra la que no uses en la prosa.

Sigla	Significado
AUC	área bajo la curva
BH	Benjamini-Hochberg
CN	colonoscopia negativa: pacientes sintomáticos con otra enfermedad intestinal
CP	colonoscopia positiva
CPTAC	Clinical Proteomic Tumor Analysis Consortium
DIA	adquisición independiente de datos
FDR	tasa de descubrimientos falsos
GO	Gene Ontology
HC	grupo medido aparte; no es el contraste que decide la pregunta
LFQ	cuantificación sin marcaje
NES	puntuación de enriquecimiento normalizada
PRM	monitoreo paralelo de reacciones
TMT	marcado isobárico en tándem
TOST	dos pruebas unilaterales
TREAT	prueba de equivalencia con un margen de cambio

1. Introducción

Objetivo de la sección. Plantear el problema, la justificación, la pregunta y los objetivos, sin prometer un examen de sangre.

% TODO Juan Diego: Redacta de 2 a 4 páginas. La guía de 2022 deja el planteamiento, la justificación y los objetivos dentro de la introducción, no como capítulos propios. Por eso este andamiaje no abre un capítulo para cada uno.

1.1 Campo y problema

- El tejido publicado ya describe el tumor y la mucosa. Tanaka et al., 2024; the NCI CPTAC et al., 2014; Vasaikar et al., 2019

- El suero es otra matriz y otras personas. El depósito que lee esta tesis es PXD055218. Rai et al., 2025

- CN no son personas sanas. HC se midió aparte y no decide la pregunta.

% TODO Juan Diego: Responde: qué se conoce del cáncer colorrectal en tejido y qué parte de ese problema aborda esta tesis. No localices las muestras en un segmento del colon.

1.2 Justificación

- La equivalencia estadística no es identidad biológica. El cero de la clase diferente no dice que el tumor no cambie en el tejido.
- No hay una cohorte nueva medida. Las redes de coexpresión no se calcularon.

% TODO Juan Diego: Escribe por qué la pregunta merece el trabajo y qué hueco no reclamas como prioridad.

1.3 Pregunta

Qué parte del cambio del tumor se deja ver en la sangre cuando el contraste es otra enfermedad intestinal.

% TODO Juan Diego: Deja la pregunta en una frase y, en otra, sus límites: matrices separadas, sin examen clínico.

1.4 Objetivos

% TODO Juan Diego: Redacta un objetivo general y los específicos en infinitivo. Una conclusión del capítulo 6 debe poder responder a cada específico.

- General, a partir de la pregunta de arriba. No lo dejes como una promesa diagnóstica.
- Específicos que el repo sí puede sostener: concordancia de signo en tejido (147 de 147); celda del suero (0, 166, 118, de 284); calidad de muestra y orden de adquisición; estado de H5 a H10.

1.5 Alcance

- Trabajo *in silico* sobre datos públicos. No propone un examen clínico. Pepe et al., 2001
- Certificado: Publicable. Sello `71b310a3fcaebe9267fac971156df3aab491e009`, 2026-11-11T00:48:45Z. Etiqueta `v3.7-final` en `595118ae09ea6006c744c86b28cb0a10d42e0442`.

Citas sugeridas: Garcia-Foncillas et al., 2026; Pepe et al., 2001; Rai et al., 2025; Tanaka et al., 2024; Vasaikar et al., 2019. Extensión orientativa: 2 a 4 páginas para todo el capítulo.

2. Marco teórico y estado del arte

Objetivo de la sección. Definir solo los conceptos que después se usan para leer un resultado, y separar el estado del arte verificado de lo que no se reabrió.

% TODO Juan Diego: Redacta este capítulo. Una subsección por concepto. No conviertas una definición en un hallazgo.

2.1 Matrices que no se fusionan

- Tejido TMT de CPTAC, estudio PDC000116. the NCI CPTAC et al., 2014; Vasaikar et al., 2019
- Réplica tisular LFQ, PXD034575: primario, metástasis hepática y mucosa. Tanaka et al., 2024
- Suero DIA, PXD055218. Rai et al., 2025
- El preregistro prohíbe fusionar cohortes y aplicar *ComBat* entre estudios.

% TODO Juan Diego: Explica, con tus palabras, por qué tejido y suero se analizan por separado. No dibujes una proteína que sale del tumor y entra a la sangre.

2.2 Cómo se declara un cambio

- Alfa 0,05. Corrección de Benjamini-Hochberg. Benjamini y Hochberg, 1995
- Margen TREAT: cambio de 1,5 veces, $\log_2(1{,}5) = 0{,}585$. McCarthy y Smyth, 2009
- TOST declara que el cambio cabe en ese margen. Lakens, 2017
- No se imputan ausencias. El cero de MaxQuant y la ausencia en DIA-NN se tratan como ausencia.

% TODO Juan Diego: Define equivalente, diferente e indeterminada con las frases del preregistro, no con una paráfrasis que las vuelva «correspondencia identificada».

2.3 Ontología y modelos

- Gene Ontology: ORA sobre una lista con umbral y GSEA sobre el ranking. Ashburner et al., 2000; Subramanian et al., 2005
- En tejido, la concordancia de NES es 16 de 16. CPTAC prueba 787 términos. Tanaka prueba 101.
- Los modelos M1 a M6 están nombrados en `config/preregistro_v3.yaml`. Un AUC interno no es rendimiento diagnóstico. Pepe et al., 2001

2.4 Estado del arte que cambia la lectura

% TODO Juan Diego: Una subsección corta por trabajo que de verdad uses. Si no reabriste el PDF, no lo cites como evidencia de un resultado propio.

- Rai 2025: suero DIA y el contraste con otra enfermedad intestinal. Rai et al., 2025
- Vasaikar 2019 y Zhang 2014: proteoma de tejido CPTAC. the NCI CPTAC et al., 2014; Vasaikar et al., 2019

- Tanaka 2024: la réplica tisular. Tanaka et al., 2024
- Xiang 2026 y Hembrough 2026: límite de los neoantígenos. No se rebuscaron péptidos. Hembrough et al., 2026; Xiang et al., 2026
- *[PENDIENTE: decidir si Seo 2026, Dhami 2026, Yu 2026, Ögren 2026, Robles 2024 y Verathamjamras 2023 entran en el cuerpo o solo quedan en la bibliografía]*

Citas sugeridas, además de las anteriores: Cox y Mann, 2008; Gabay y Kushner, 1999; Geyer et al., 2019; Leek et al., 2010; Smyth, 2004. Extensión orientativa: 8 a 15 páginas.

3. Materiales y métodos

Objetivo de la sección. Describir datos, reglas fijadas antes de leer el resultado, y el entorno, de forma que otra persona pueda repetir la corrida.

% TODO Juan Diego: Lo que sigue es descriptivo y sale del preregistro y del certificado. Revísalo y reescríbelo con tus palabras. No cambies un umbral.

3.1 Cohortes

Cuadro 3.1: Matrices leídas por la corrida v3.7

Matriz	Acceso	Papel en esta tesis
Tejido TMT, CPTAC	PDC000116	Tumor frente a normal publicado. Fuente: `config/datasets.yaml`. Vasaikar et al., 2019
Tejido LFQ	PXD034575	Primario, metástasis hepática y mucosa. Fuente: `k1_etiquetas`. Tanaka et al., 2024
Suero DIA	PXD055218	Celda CP frente a CN. Fuente: `k4_suero`. Rai et al., 2025
Suero de otro depósito	PXD064655	No se calculó su contraste proteómico. H8 queda No evaluable.

Fuente: `config/preregistro_v3.yaml` y `config/datasets.yaml`.

3.2 Reglas de inferencia

- Alfa 0,05. Benjamini-Hochberg. Margen $\log_2(1{,}5) = 0{,}585$. Mínimo de pares observados: 3. Mínimo por grupo en suero: 8. Fracción mínima observada: 0,70.
- No se fusionan matrices. No se imputa. No se aplica un segundo $\log_2$ a CPTAC.
- Celda preregistrada del multiverso: PG.MaxLFQ, librería v3.3, paneles excluidos, mínimo $n = 3$, margen 0,585, alfa 0,05, sin normalización de tejido.
- Clases del suero: diferente si TREAT pasa el corte en el sentido observado; equivalente si TOST cabe en el margen; indeterminada si queda fuera de las otras dos.

% TODO Juan Diego: Confirma en el código si los desplazamientos 720, 721, 840 y 841 se suman a la semilla base. El JSON de la corrida guarda la semilla `20260914` en `ml_suero_permutacion.json` y en `h7_visibilidad_en_sangre.json`.

3.3 Modelos y priorización

- M1 a M6, con los nombres de la enmienda: matriz humana, matriz principal, solo calidad, solo coagulación, principal residualizada por la calidad, y cinco componentes dentro del pliegue.
- Validación escrita: 5 pliegues estratificados, 20 repeticiones, nulo de 1000 permutaciones.
- Regla titular: si M2 no pasa la permutación, no hay separación detectable; si M2 y M5 pasan y el AUC de M5 es al menos 0,70, la señal va más allá de la calidad; en otro caso la separación se explica por la calidad.
- Embudo de priorización, en este orden: 688, 135, 135, 118, 20, 0, 0. Nadie pasa el paso 6.

3.4 Lo que el método no hizo

- Vías del suero, cláusula de vías de H1, unión de HC por XIC, deriva del PRTC, redes de coexpresión, catálogo de candidatas y neoantígenos. Están declarados como no ejecutados. No son un resultado.
- H8: 0 tumorales epiteliales en un universo de 53. directLFQ 0.3.3 figura en el JSON. Ammar et al., 2023

3.5 Entorno

Python 3.14.3. numpy 2.4.4, pandas 3.0.2, scipy 1.17.1, scikit-learn 1.8.0. Semilla registrada en el sello: 20260914. Fuente: `results/v3_7/certificado.json`.

3.6 Uso de herramientas de inteligencia artificial

% TODO Juan Diego: Ajusta este párrafo. La versión de Cursor y la fecha de SciSpace ya están en la declaración.

Se utilizó Cursor (Anysphere) como asistente de programación para escribir y depurar código, y SciSpace como apoyo para buscar y hacer un primer filtro de literatura científica. El código, los resultados y las fuentes fueron revisados, ejecutados y validados por el autor, quien asume la responsabilidad total del contenido. Anysphere, 2026; SciSpace, 2026

Cursor y SciSpace no se citan como fuente de un hecho científico. Extensión orientativa: 8 a 12 páginas.

4. Resultados

Objetivo de la sección. Mostrar cada cifra con su figura o su tabla, y decir en la misma página qué no demuestra.

% TODO Juan Diego: Redacta el puente entre la figura y la cifra. El caption de abajo es técnico y provisional.

4.1 Mapa de la corrida

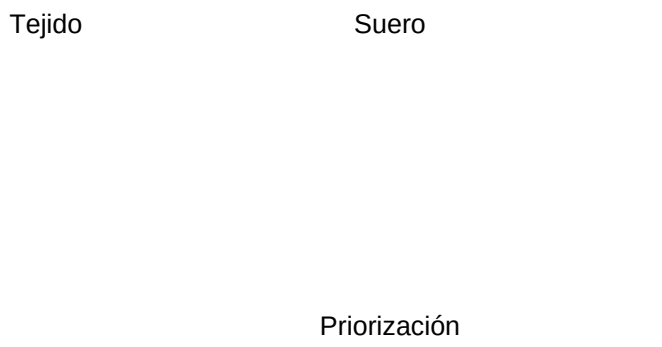


Figura 4.1: Cuatro bloques de la corrida: tejido, suero, hipótesis y priorización. El trazo une el orden de lectura. No representa una proteína que pasa del tumor a la sangre.

Fuente: `scripts/v3/exportar_sitio_v3_7.py`, figura `f01`, a partir de `results/v3_7/`.

% TODO Juan Diego: escribe tu interpretación de la figura 4.1.

4.2 Tejido

- Signo del tumor primario, Tanaka frente a CPTAC: 147 de 147.
- Metástasis hepática frente a mucosa: 116 de 143.
- Cobertura: 147 de 688. Veredicto de H1: Rechaza H1.
- Concordancia de NES: 16 de 16.

Figura 4.2: Cada punto es un gen de la tabla de H7 medido también en Tanaka. El eje horizontal es el $\log_2$FC de CPTAC y el vertical, el de Tanaka.

Fuente: `results/v3_7/`, figura `f05`.

% TODO Juan Diego: escribe tu interpretación de la figura 4.2. No afirmes que el signo compartido localiza una muestra.

Fuente: `results/v3_7/go_tejido.json`, figura `f07`.

% TODO Juan Diego: escribe tu interpretación de la figura 4.3. Un ORA de cero términos en Tanaka no es ausencia de biología: Tanaka tiene 0 términos ORA que suben y 0 que bajan,

Figura 4.3: Cada punto es un término con FDR de CPTAC dentro del umbral y con NES en Tanaka.

y 21 con GSEA.

4.3 Suero

Cuadro 4.1: Celda preregistrada del suero, CP frente a CN

Clase	Proteínas
Diferentes	0
Equivalentes	166
Indeterminadas	118
Total	284

Fuente: `results/v3_7/suero_embudo.json`, campo `celda_preregistrada`.

% TODO Juan Diego: El cero no lleva un segmento inventado. No escribas que la equivalencia estadística es identidad biológica.

Fuente: `results/v3_7/suero_embudo.json`, figura `f02`.

% TODO Juan Diego: escribe tu interpretación de la figura 4.4.

Fuente: `suero_k4_crc_sanos.tsv` y `suero_k4_cn_sanos.tsv`, figura `f03`.



Figura 4.4: Embudo del suero. Alturas: 897 grupos, 329 con el filtro global, 312 humanas y la celda de 284.

% TODO Juan Diego: escribe tu interpretación de la figura 4.5. No llames sanos a CN.

4.4 Calidad, orden y modelos

- Preanalítica: estado Calculado. Crudos válidos: 60. Con fecha: 60. AUC del orden: 0,000. p exacta de Mann-Whitney: $1{,}5 \times 10^{-11}$. Es el valor de `cifras.tex` (`\PreP`); va en fórmula porque la fuente no tiene el signo de exponente.
- M2, todas las proteínas: AUC 0,880. M3, solo calidad: 0,915. M5, sin la calidad: 0,647, p 0,12.
- M1: 0,947. M4, coagulación: 0,818. M6: 0,887.

Fuente: `results/v3_7/ml_suero_permutacion.json`, figura `f08`.

% TODO Juan Diego: escribe tu interpretación de la figura 4.6. No presentes el AUC como sensibilidad ni como especificidad de un examen.

Fuente: Figura `f09`.

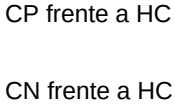


Figura 4.5: La barra superior es CP frente a CN. Las de abajo son los contrastes con HC, medido aparte: 3 diferentes en CP y 1 en CN. HC no decide la pregunta.

% TODO Juan Diego: escribe tu interpretación de la figura 4.7.

4.5 Hipótesis y priorización

Cuadro 4.2: Estado de las hipótesis en la corrida firmada

Hipótesis	Estado	Cifra que sí está
H5	Sostiene	29 genes en el universo principal. Fracción pan-carcinoma 0,119. Clasifica 624 proteínas.
H6	No sostiene	No informa a favor ni en contra.
H7	Refuta	Álvez 2023: AUC 0,483. HPA: AUC 0,464. Secundario: 0,47377, con vector en 668 y 20 omitidas.
H8	No evaluable	0 tumorales epiteliales en 53.
H9	Exploratorio	No decide la tesis.
H10	Descriptiva	5 proteínas.

Fuente: JSON `h5` a `h10` de `results/v3_7/`.

% TODO Juan Diego: El intervalo de Álvez es 0,381 a 0,584 (53 y 73) y el del HPA es 0,353 a 0,573 (53 y 63). Papier 2024 queda no evaluable: 1 y 125. Escribe eso solo si usas H7.



Figura 4.6: AUC fuera de pliegue de M1 a M6. La línea discontinua es el percentil 95 del nulo de K5.

- Pasos de priorización: 688, 135, 135, 118, 20, 0 y 0.
- Del paso 5, 18 bajan en CPTAC y 2 suben.
- Multiverso: 288 celdas de suero, 72 de aprendizaje, 13 con alguna proteína diferente.

Fuente: `results/v3_7/multiverso_resumen.json`, figura `f04`.

% TODO Juan Diego: escribe tu interpretación de la figura 4.8.

Fuente: Figura `f06`. [PENDIENTE: verificar en `results/v3_7/` el veredicto de CA1 antes de escribirlo en la prosa. El anexo viejo decía «CA1 pasa» y no se copió aquí.]

% TODO Juan Diego: escribe tu interpretación de la figura 4.9 solo con el fichero que abras.

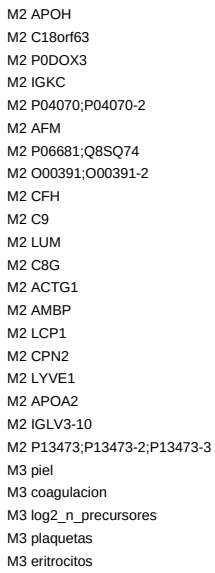


Figura 4.7: Media del valor absoluto de SHAP en M2 y en M3. M3 usa las variables de calidad que trae el fichero.

Figura 4.8: Rejilla de 288 celdas. El trazo discontinuo marca las que tienen alguna proteína diferente. No es una cohorte nueva.

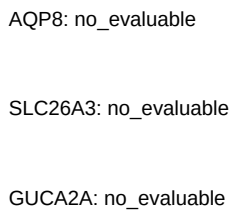


Figura 4.9: Controles de tejido no medibles. AQP8, GUCA2A y SLC26A3 quedan con trazo discontinuo porque el fichero no los da para la prueba.

5. Discusión

Objetivo de la sección. Interpretar los resultados, incluir las limitaciones y no convertir una desviación en un hallazgo.

% TODO Juan Diego: Redacta la discusión. Las viñetas son el material, no el párrafo.

5.1 Qué se puede leer

- En tejido, el signo del tumor primario coincide en 147 de 147. Eso no confirma todas las etiquetas de tumor y mucosa.
- En suero, 0 de 284 separan el cáncer de la colonoscopia negativa. 166 son equivalentes y 118 indeterminadas.
- El modelo con todas las proteínas da 0,880, la calidad sola da 0,915 y sin la calidad el área cae a 0,647 (p 0,12).
- H7 queda en Refuta. Las variables del tejido fijadas de antemano no anticipan el cambio en sangre.

% TODO Juan Diego: Responde: ¿la separación de los grupos es una proteína del tumor o va con la calidad de la muestra? Cita Leek et al., 2010; Pepe et al., 2001; Rai et al., 2025.

5.2 Limitaciones

- Es trabajo *in silico*. No propone un examen clínico.
- No hay tejido y sangre de la misma persona en las matrices usadas.
- CP, CN y HC se midieron en bloques. El orden y el grupo no se pueden separar. Estado de la preanalítica: Calculado.
- H8 queda en No evaluable. Eso no dice que el estadio IV no lleve proteína del tumor a la sangre.
- El cero de la clase diferente no dice que el tumor no cambie en el tejido.
- *[PENDIENTE: si vas a afirmar que no hay población latinoamericana en estos depósitos, cita el fichero que lo diga. Aquí no se inventa esa frase.]*

5.3 Desviaciones del preregistro

% TODO Juan Diego: Esta sección absorbe el antiguo capítulo de desviaciones para dejar la tesis en seis capítulos. El detalle escrito sigue en `chapters/11-desviaciones.tex`, que ya no entra en `main.tex`.

- No se ejecutaron las vías del suero, la cláusula de vías de H1, la unión de HC por XIC, la deriva del PRTC, las redes, el catálogo de candidatas ni los neoantígenos.
- H9 queda en Exploratorio. El preregistro lo declara como desviación de procedimiento y dice que no decide la tesis.
- El paso 5 deja 20 genes como hipótesis para cohortes futuras. El paso 6 queda en 0.

Citas sugeridas: Hembrough et al., 2026; Lakens, 2017; McCarthy y Smyth, 2009; Rai et al., 2025; Xiang et al., 2026. Extensión orientativa: 6 a 10 páginas.

6. Conclusiones y recomendaciones

Objetivo de la sección. Una conclusión por objetivo, y cada una con lo que no demuestra. Las recomendaciones no anticipan un número.

% TODO Juan Diego: Redacta las conclusiones en impersonal. No añadas un objetivo que no esté en la introducción.

6.1 Conclusiones

1. Tejido: 147 de 147. H5 queda en Sostiene, universo de 29 genes. Qué no demuestra: no confirma todas las etiquetas.
2. Suero: 0 de 284 diferentes, 166 equivalentes, 118 indeterminadas. AUC 0,880, 0,915 y 0,647 (p 0,12). Qué no demuestra: no es un examen y no detecta una proteína del tumor.
3. Preanalítica en estado Calculado, con fecha en 60 de 60 crudos. Qué no demuestra: no separa el grupo del lote.
4. H6 queda en No sostiene. H7 queda en Refuta. H8 queda en No evaluable, con 0 tumorales epiteliales en 53. Qué no demuestra: no dice que el estadio IV no lleve proteína del tumor a la sangre.
5. H9 queda en Exploratorio y H10 queda en Descriptiva, con 5 proteínas. Qué no demuestra: no decide la tesis.

% TODO Juan Diego: Reescribe cada ítem como una frase tuya. Conserva la cifra y la frase

«qué no demuestra».

6.2 Recomendaciones y trabajo futuro

- La siguiente medición debe aleatorizar el orden, intercalar los grupos y repetir el contraste en otra cohorte de personas con síntomas.
- Hasta entonces el certificado queda en Publicable y no se propone un examen de sangre.
- *[PENDIENTE: no anticipes un AUC, una sensibilidad ni un tamaño de cohorte futura.]*

Extensión orientativa: 2 a 4 páginas.

7. Anexos

Objetivo de la sección. Dejar el código, el entorno y las tablas suplementarias localizables, sin convertir un fichero ausente en un resultado.

% TODO Juan Diego: Elige qué tablas suplementarias vas a pegar. No pegues una corrida anterior como si fuera la v3.7.

7.1 Correspondencia con la propuesta

La tabla sale de `config/correspondencia_propuesta.tsv`. La palabra «cumplido» es la etiqueta de ese fichero. No la conviertas en un biomarcador ni en una cohorte nueva.

Punto	**Estado**	**Dónde está**
Integrar la proteómica de las tres cohortes	cumplido	suero_embudo.json
Proteínas diferenciales en suero	cumplido	suero_k4_crc_cn.tsv. Frente a CN ninguna proteína de la celda es diferente. CN no son personas sanas. Frente a HC salen 3 (CP) y 1 (CN), leídos de suero_k4_crc_sanos.tsv y suero_k4_cn_sanos.tsv.
Reproducibilidad entre cohortes de tejido	cumplido_reformulado	k1_etiquetas.json
Priorización de candidatas	cumplido_reformulado	priorizacion_embudo.json
GO ORA y GSEA del tejido	cumplido	go_tejido.json
Redes de coexpresión	desviacion_declarada	preregistro_v2.hipotesis.h2
Aprendizaje automático interpretable	cumplido	ml_explicacion.json
Score de candidatas	cumplido_reformulado	priorizacion.tsv
Ampliar cohortes	no_cumplido	trabajo futuro
Robustecer la validación	cumplido	certificado.json

7.2 Entorno y código

- Certificado: `results/v3_7/certificado.json`. Estado Publicable.
- Sello: `71b310a3fcaebe9267fac971156df3aab491e009`, 2026-11-11T00:48:45Z.
- Etiqueta: `v3.7-final`, commit `595118ae09ea6006c744c86b28cb0a10d42e0442`.
- Preregistro: `config/preregistro_v3.yaml`.
- Cifras de este PDF: `tesis-ucaldas/latex/cifras.tex`, generado por `scripts/v3/exportar_cifras_v3_7`
- Figuras `f01` a `f09`: `scripts/v3/exportar_sitio_v3_7.py`. Copias en `tesis-ucaldas/figures/` y en `tesis-ucaldas/latex/figures/`.

- No hay PNG a 300 dpi: en esta máquina no están cairosvg ni Inkscape. El PDF usa los vectoriales y los SVG quedan en `tesis-ucaldas/figures/`.
- Figuras `F1` a `F14`: el sello de `F1` dice etapa `v3_3_figuras`, 2026-11-09. No entran en este andamiaje como cifras de la corrida firmada.

7.3 Ficheros que la especificación nombra y no están

`vias_suero.json`, `h1_vias.json`, `catalogo_auditoria.tsv`, `neoantigenos.tsv` y `prtc_por_corrida.tsv`
La ausencia está declarada. No es un resultado. Fuente: `docs/estado_v3_7.md`.

Referencias bibliográficas

Ammar, C., Schessner, J. P., Rath, S., Troppmair, P., Patron, A., Scholz, R., Jarzab, A., & Mann, M. (2023). Accurate Label-Free Quantification by directLFQ to Compare Unlimited Numbers of Proteomes. *Molecular & Cellular Proteomics*, *22*(7), 100581. https://doi.org/10.1016/j.mcpro.2023.100581

Anysphere. (2026). Cursor [Versión 3.28.7. No es fuente de un hecho científico.]. https://cursor.com

Ashburner, M., Ball, C. A., Blake, J. A., Botstein, D., Butler, H., Cherry, J. M., Davis, A. P., Dolinski, K., Dwight, S. S., Eppig, J. T., Harris, M. A., Hill, D. P., Issel-Tarver, L., Kasarskis, A., Lewis, S., Matese, J. C., Richardson, J. E., Ringwald, M., Rubin, G. M., & Sherlock, G. (2000). Gene Ontology: tool for the unification of biology. *Nature Genetics*, *25*(1), 25-29. https://doi.org/10.1038/75556

Benjamini, Y., & Hochberg, Y. (1995). Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, *57*(1), 289-300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x

Congreso de la República de Colombia. (2010). Ley 1384 de 2010, por la cual se establecen las acciones para la atención integral del cáncer en Colombia.

Cox, J., & Mann, M. (2008). MaxQuant enables high peptide identification rates, individualized p.p.b.-range mass accuracies and proteome-wide protein quantification. *Nature Biotechnology*, *26*(12), 1367-1372. https://doi.org/10.1038/nbt.1511

Dhami, J., Radhakrishnan, S. K., Russ, D., Mondal, S., Alzarooni, A., Merodio, L. B., Duggal, N. A., Gupta, R., & Acharjee, A. (2026). A Network-Based Association of IBD and Colorectal Cancer Using Proteomics Data. *PROTEOMICS – Clinical Applications*, *20*(2). https://doi.org/10.1002/prca.70041

Gabay, C., & Kushner, I. (1999). Acute-Phase Proteins and Other Systemic Responses to Inflammation. *New England Journal of Medicine*. https://doi.org/10.1056/NEJM199902113400607

Garcia-Foncillas, J., Jiménez-Vásquez, P., Avila-Rodriguez, V., Guerrero-Macías, S., Manrique, M. E., Rendón-Hernández, J., Montano Angarita, J., Calvo, J. F., & Bonilla, C. E. (2026). Biología molecular del cáncer colorrectal. *Revista Colombiana de Hematología y Oncología*, *13*(1S), 281-309. https://doi.org/10.51643/22562915.853

Geyer, P. E., Voytik, E., Treit, P. V., Doll, S., Kleinhempel, A., Niu, L., Müller, J. B., Buchholtz, M.-L., Bader, J. M., Teupser, D., Holdt, L. M., & Mann, M. (2019). Plasma Proteome Profiling to detect and avoid sample-related biases in biomarker studies. *EMBO Molecular Medicine*. https://doi.org/10.15252/emmm.201910427

Hembrough, T., Ezrin, A. M., Opheim, Z., Bandoski, C., Bennett, S., Fagan-Solis, K., Vincent, B. G., & Hoos, W. (2026). Abstract 7710: Extracellular vesicle immunopeptidomics recovers immunogenic neoantigen peptides from cancer patient plasma. *Cancer Research*, *86*(7_Supplement), 7710-7710. https://doi.org/10.1158/1538-7445.am2026-7710

Hermoso-Durán, S., et al. (2026). Integrating thermal liquid biopsy, clinical data, and mass spectrometry for early diagnosis and biomarker discovery in colorectal cancer. *iScience*, *29*(2), 114751. https://doi.org/10.1016/j.isci.2026.114751

Hulstaert, N., Shofstahl, J., Sachsenberg, T., Walzer, M., Barsnes, H., Martens, L., & Perez-Riverol, Y. (2019). ThermoRawFileParser: Modular, Scalable, and Cross-Platform RAW File Conversion. *Journal of Proteome Research*, *19*(1), 537-542. https://doi.org/10.1021/acs.jproteome.9b00328

Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Žídek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., … Hassabis, D. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, *596*(7873), 583-589. https://doi.org/10.1038/s41586-021-03819-2

Lakens, D. (2017). Equivalence Tests. *Social Psychological and Personality Science*, *8*(4), 355-362. https://doi.org/10.1177/1948550617697177

Leek, J. T., Scharpf, R. B., Bravo, H. C., Simcha, D., Langmead, B., Johnson, W. E., Geman, D., Baggerly, K., & Irizarry, R. A. (2010). Tackling the widespread and critical impact of batch effects in high-throughput data. *Nature Reviews Genetics*. https://doi.org/10.1038/nrg2825

Lesur, A., Bernardin, F., Koncina, E., Letellier, E., Kruppa, G., Schmit, P.-O., & Dittmar, G. (2023). Quantification of 782 Plasma Peptides by Multiplexed Targeted Proteomics. *Journal of Proteome Research*, *22*(6), 1630-1638. https://doi.org/10.1021/acs.jproteome.2c00575

Li, Y., Wang, B., Yang, W., Ma, F., Zou, J., Li, K., Tan, S., Feng, J., Wang, Y., Qin, Z., Chen, Z., & Ding, C. (2024). Longitudinal plasma proteome profiling reveals the diversity of biomarkers for diagnosis and cetuximab therapy response of colorectal cancer. *Nature Communications*, *15*(1). https://doi.org/10.1038/s41467-024-44911-1

Locker, G. Y., Hamilton, S., Harris, J., Jessup, J. M., Kemeny, N., Macdonald, J. S., Somerfield, M. R., Hayes, D. F., & Bast, R. C. (2006). ASCO 2006 Update of Recommendations for the Use of Tumor Markers in Gastrointestinal Cancer. *Journal of Clinical Oncology*. https://doi.org/10.1200/jco.2006.08.2644

Malmström, E., Malmström, L., Hauri, S., Mohanty, T., Scott, A., Karlsson, C., Gueto-Tettay, C., Åhrman, E., Nozohoor, S., Tingstedt, B., Regner, S., Elfving, P., Bjermer, L., Forsvall, A., Doyle, A., Magnusson, M., Hedenfalk, I., Kannisto, P., Brandt, C., … Malmström, J. (2025). Human proteome distribution atlas for tissue-specific plasma proteome dynamics. *Cell*, *188*(10), 2810-2822.e16. https://doi.org/10.1016/j.cell.2025.03.013

McCarthy, D. J., & Smyth, G. K. (2009). Testing significance relative to a fold-change threshold is a TREAT. *Bioinformatics*, *25*(6), 765-771. https://doi.org/10.1093/bioinformatics/btp053

Ögren, J. Å., Ekström, J., Rameika, N., Torell, E., Larsson, C., Stoimenov, I., Micke, P., Gyllensten, U., Hellström, M., Glimelius, B., Stålberg, K., & Sjöblom, T. (2026). Composite proteomic and metabolomic plasma biomarkers for detection of colorectal, lung and ovarian cancers. *Molecular Cancer*, *25*(1). https://doi.org/10.1186/s12943-026-02654-1

Pepe, M. S., Etzioni, R., Feng, Z., Potter, J. D., Thompson, M. L., Thornquist, M., Winget, M., & Yasui, Y. (2001). Phases of Biomarker Development for Early Detection of Cancer. *JNCI Journal of the National Cancer Institute*. https://doi.org/10.1093/jnci/93.14.1054

Rai, A. B., Codi, J. A. K., Kotimoole, C. N., Ramesh, P., Narayana, V. K., Shaji, V., & Prasad, T. S. K. (2025). Data-Independent Acquisition Analysis to Identify Serum Biomarkers and Neoantigens for Differentiating Colorectal Cancer from Inflammatory Bowel Diseases. *Journal of Proteome Research*, *24*(8), 4166-4180. https://doi.org/10.1021/acs.jproteome.5c00285

Robles, J., Prakash, A., Vizcaíno, J. A., & Casal, J. I. (2024). Integrated meta-analysis of colorectal cancer public proteomic datasets for biomarker discovery and validation. *PLOS Computational Biology*, *20*(1), e1011828. https://doi.org/10.1371/journal.pcbi.1011828

SciSpace. (2026). SciSpace [Consultado entre 2026-03 y 2026-11. No es fuente de un hecho científico.]. https://scispace.com

Seo, Y., Han, Y. D., Bojmar, L., Kim, K.-A., Seo, Y., Kim, T. K., Lee, S., Kim, Y., Choi, H. B., Lim, Y. H., Kim, C. H., Sandberg, A., Fan, C., Lauritzen, P., Molina, H., Peralta, C., Geri, J. B., Burdette, C., Han, D. H., … Kim, H. S. (2026). Proteomic Profiling of Human Extracellular Vesicles Reveals Diagnostic Biomarkers for Colon Adenocarcinoma. *Journal of Extracellular Vesicles*, *15*(4). https://doi.org/10.1002/jev2.70278

Smyth, G. K. (2004). Linear Models and Empirical Bayes Methods for Assessing Differential Expression in Microarray Experiments. *Statistical Applications in Genetics and Molecular Biology*, *3*(1), 1-25. https://doi.org/10.2202/1544-6115.1027

Subramanian, A., Tamayo, P., Mootha, V. K., Mukherjee, S., Ebert, B. L., Gillette, M. A., Paulovich, A., Pomeroy, S. L., Golub, T. R., Lander, E. S., & Mesirov, J. P. (2005). Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*, *102*(43), 15545-15550. https://doi.org/10.1073/pnas.0506580102

Tanaka, A., Ogawa, M., Zhou, Y., Namba, K., Hendrickson, R. C., Miele, M. M., Li, Z., Klimstra, D. S., Buckley, P. G., Gulcher, J., Wang, J. Y., & Roehrl, M. H. (2024). Proteogenomic characterization of primary colorectal cancer and metastatic progression identifies proteome-based subtypes and signatures. *Cell Reports*, *43*(2), 113810. https://doi.org/10.1016/j.celrep.2024.113810

the NCI CPTAC, Zhang, B., Wang, J., Wang, X., Zhu, J., Liu, Q., Shi, Z., Chambers, M. C., Zimmerman, L. J., Shaddox, K. F., Kim, S., Davies, S. R., Wang, S., Wang, P., Kinsinger, C. R., Rivers, R. C., Rodriguez, H., Townsend, R. R., Ellis, M. J. C., … Liebler, D. C. (2014). Proteogenomic characterization of human colon and rectal cancer. *Nature*, *513*(7518), 382-387. https://doi.org/10.1038/nature13438

Uhlén, M., Fagerberg, L., Hallström, B. M., Lindskog, C., Oksvold, P., Mardinoglu, A., Sivertsson, Å., Kampf, C., Sjöstedt, E., Asplund, A., Olsson, I., Edlund, K., Lundberg, E., Navani, S., Szigyarto, C. A.-K., Odeberg, J., Djureinovic, D., Takanen, J. O., Hober, S., … Pontén, F. (2015). Tissue-based map of the human proteome. *Science*, *347*(6220). https://doi.org/10.1126/science.1260419

Vasaikar, S., Huang, C., Wang, X., Petyuk, V. A., Savage, S. R., Wen, B., Dou, Y., Zhang, Y., Shi, Z., Arshad, O. A., Gritsenko, M. A., Zimmerman, L. J., McDermott, J. E., Clauss, T. R., Moore, R. J., Zhao, R., Monroe, M. E., Wang, Y.-T., Chambers, M. C., … Zhang, Z. (2019). Proteogenomic Analysis of Human Colon Cancer Reveals New Therapeutic Opportunities. *Cell*, *177*(4), 1035-1049.e19. https://doi.org/10.1016/j.cell.2019.03.030

Verathamjamras, C., Chantaraamporn, J., Sornprachum, T., Mutapat, P., Chokchaichamnankit, D., Mingkwan, K., Luevisadpibul, V., Srisomsap, C., Chutipongtanate, S., Svasti, J., & Champattanachai, V. (2023). Label-free quantitative proteomics reveals aberrant expression levels of LRG, C9, FN, A1AT and AGP1 in the plasma of patients with colorectal cancer. *Clinical Proteomics*, *20*(1). https://doi.org/10.1186/s12014-023-09407-y

Xiang, H., Guan, X., Wei, Y., Luo, S., Zhang, H., Bu, F., Yan, Y., Fu, Y., Li, Y., Xu, Q., Lin, P., Liu, D., Zhou, X., Gao, F., Chen, T., Nie, G., Wu, K., Gu, Y., Liu, L., … Dong, X. (2026). Predominant mutated non-canonical tumor-specific antigens identified by

proteogenomics demonstrate immunogenicity and tumor suppression in CRC. *Cell Genomics*, *6*(1), 101062. https://doi.org/10.1016/j.xgen.2025.101062

Yu, Y., Jiang, X., Pei, B., Zhou, J., Long, Z., Cao, Y., Ye, J., Gao, Y., Xie, K., Yuan, H., Jia, Y., Zhang, M., Liu, X., Zhao, Y., Ning, H., & Wang, F. (2026). Proteome profiling reveals early diagnostic biomarker candidates for colorectal cancer. *BMC Cancer*, *26*(1). https://doi.org/10.1186/s12885-026-15547-9